

# M1 SDSC

## UE données complexes

TP – Avril-mai 2026 – F. Le Ber, X. Dolques

Vous avez vu dans les séances précédentes les caractéristiques de données concernant la qualité de l'eau des cours d'eau français. Pour les TP, vous devrez mobiliser ces données et d'autres à votre disposition pour établir une analyse de ces données permettant de répondre à une question.

### But

Nous mettons à votre disposition un jeu de données contenant un ensemble de stations du réseau de contrôle et surveillance (RCS) des eaux douces de surface. Des jeux de données différents (de différentes zones géographiques) sont disponibles.

Pour ces stations nous fournissons des données issues de prélèvements physico-chimiques. Ces données concernent les paramètres physico-chimiques les plus importants et les mieux renseignés, garantissant ainsi une quantité minimale de données.

Le but des TP est de proposer une réponse à la question « Quels sont les liens entre les différents paramètres, et peut-on définir des classes de qualité des stations en relation avec leur localisation géographique ? ». Différentes étapes seront suivies au cours des 3 séances de TP pour répondre à cette question. On s'appuiera sur des informations complémentaires issues des travaux de normalisation en hydroécologie (SANDRE).

La dernière séance (TP noté) aura pour objectif de mettre en œuvre la méthode sur un nouveau jeu de données.

Il est à noter que cette question est à l'heure actuelle un problème ouvert et qu'il n'existe par conséquent pas de réponse unique et absolue. Ainsi l'évaluation du TP ne portera pas tant sur un résultat que sur l'explication de la démarche et l'interprétation des résultats.

### Mise en œuvre

#### ***TP 1 : étude préliminaire et sélection des paramètres***

- Étude des données brutes, compréhension et sélection des informations utiles dans les fichiers,
- Statistiques descriptives, visualisation des distributions de valeurs des paramètres physico-chimiques
- Étude de la répartition par rapport aux classes de qualité du modèle SANDRE
- Étude de la complétion des différents paramètres physico-chimiques sur les différentes stations (suppression des stations atypiques)

- Étude des corrélations entre paramètres physico-chimiques, au regard des regroupements du SANDRE

## **TP 2 : agrégation des données et clustering**

Les données sont sous forme de séquences, pour simplifier le problème des agrégations sont nécessaires . Deux approches seront étudiées :

- Agrégation par la moyenne annuelle
- Agrégation par percentile : c'est l'agrégation utilisée dans le domaine pour mettre en exergue les 'mauvaises' valeurs

Pour le *clustering*, le choix du nombre de classes doit tenir compte du nombre de classes de qualité selon le SANDRE.

## **TP 3 : Visualisation géographique, interprétation**

On utilise les données de *corine land cover* comme fond de carte pour afficher les classes obtenues

- téléchargement : <https://www.statistiques.developpement-durable.gouv.fr/corine-land-cover-0>
- Choix de la date, choix du niveau d'information 2
- On peut compléter avec le réseau hydrographique (BD carthage) : <https://www.data.gouv.fr/fr/datasets/bd-carthage-r/>
- Affichage et interprétation

## **TP4 noté**

Le TP sera effectué en binôme. Nous vous demandons de fournir à l'issue du TP un rapport décrivant votre démarche et votre analyse des résultats obtenus pour répondre à la question, accompagné du notebook que vous avez utilisé. Le rapport doit faire de 4 à 6 pages hors figures ou tableaux.

Le rapport devra notamment décrire :

- **Les données mobilisées.** Vous avez la possibilité d'enrichir les données fournies par d'autres données disponibles en accès libre. Lorsque vous intégrez à votre travail un nouveau jeu de données, vous êtes amenés à procéder à certaines opérations d'analyse et de transformation de ces données qu'il vous faudra décrire.
- **Les outils utilisés.** Vous avez le choix d'utiliser les outils et techniques qui vous semblent les plus pertinents.
- **Les résultats obtenus aux différentes étapes** sous la forme qui vous apparaît la plus pertinente. Ces résultats devront amener à une discussion sur la démarche employée et ses limites.